

- 1 PRESENTATON DE LA
BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU
REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA
BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA
BASE DE DONNEES :
- 8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE
DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

Heart Failure Prevision

Lajoie BENGONE AKOU & Jean-Luc AYIVOR

2026-01-06

1 PRESENTATON DE LA BASE DE DONNEES

La base de données **Heart Failure Clinical Records**

(<https://archive.ics.uci.edu/dataset/519/heart+failure+clinical+records>) contient les dossiers médicaux de 299 patients atteints d'insuffisance cardiaque, recueillis pendant leur période de suivi, chaque profil de patient comportant 13 caractéristiques cliniques qui se présentent comme suit :

- age : age of the patient (year)
- anaemia : decrease of red blood cells or hemoglobin (.)
- creatinine_phosphokinase : level of the CPK enzyme in the blood (mcg/L)
- diabetes : if the patient has diabetes (.)
- ejection_fraction : percentage of blood leaving the heart at each contraction (%)
- high_blood_pressure : if the patient has hypertension (.)
- platelets : platelets in the blood (kiloplatelets/mL)
- serum_creatinine : level of serum creatinine in the blood (mg/dL)
- serum_sodium : level of serum sodium in the blood (mEq/L)
- sex : Sex woman or man (.)
- smoking : if the patient smokes or not (.)
- time : follow-up period (days)
- DEAHT_EVENT : if the patient died during the follow-up period (.)

2 OBJECTIF

L'objectif de cette étude est de prédire si un patient atteint d'insuffisance cardiaque va décéder pendant la période de suivi ou pas selon le niveau de sévérité de ses caractéristiques médicales. source (<http://heart.org/en/health-topics/heart-failure/what-is-heart-failure/classes-of-heart-failure#:~:text=Heart%20failure%20can%20progress.,how%20bad%20the%20symptoms%20are>)

3 ORGANISATION DU REPERTOIRE DE TRAVAIL

3.1 Définition du répertoire de travail

```
# Chargement du répertoire de travail
setwd("C:/Users/lajoi/Documents/0_PARCOURS UNIVERSITAIRE/3_MASTER_2024_2026/UPEC - M2 - S1 - MASE
RATI DA/Scoring/HeartFailurePrediction")
```

3.2 Création des dossiers pour les inputs et outputs

```
data_input_url <- "data_input"
data_input <- ifelse(dir.exists(data_input_url)==TRUE, print("Le dossier existe déjà"), dir.creat
e(data_input_url))
```

```
## [1] "Le dossier existe déjà"
```

```
data_output_url <- "data_output"
data_output <- ifelse(dir.exists(data_output_url)==TRUE, print("Le dossier existe déjà"), dir.cre
ate(data_output_url))
```

```
## [1] "Le dossier existe déjà"
```

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

- 1 PRESENTATON DE LA
BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU
REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA
BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA
BASE DE DONNEES :
- 8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE
DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN

4.1 Installation du package avec pacman

```
#install.packages("pacman", repos = "http://cran.us.r-project.org") # install.packages("pacman")
```

4.2 Chargement du package avec la méthode pacman

```
library(pacman)
```

```
## Warning: le package 'pacman' a été compilé avec la version R 4.5.2
```

4.2.1 Chargement des librairies

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
p_load("tidyverse",
      "ggplot2",
      "stargazer",
      "cluster",
      "factoextra",
      "dendextend",
      "clue",
      "caret",
      "flexclust",
      "MASS",
      "caret",
      "candisc",
      "klaR",
      "class",
      "pROC",
      "rpart",
      "rpart.plot",
      "tree",
      "ggcorrplot")
```

5 CHARGEMENT DE LA BASE DE DONNES

```
HeartFailure <- read.csv("Data_input/heart_failure_clinical_records_dataset.csv", sep = ",")
HeartFailure |> head(5)
```

- 1 PRESENTATON DE LA
BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU
REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA
BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA
BASE DE DONNEES :
- 8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE
DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
##   age anaemia creatinine_phosphokinase diabetes ejection_fraction
## 1  75         0                      582         0                20
## 2  55         0                      7861        0                38
## 3  65         0                      146         0                20
## 4  50         1                      111         0                20
## 5  65         1                      160         1                20
##   high_blood_pressure platelets serum_creatinine serum_sodium sex smoking time
## 1                   1    265000                1.9         130    1         0     4
## 2                   0    263358                1.1         136    1         0     6
## 3                   0    162000                1.3         129    1         1     7
## 4                   0    210000                1.9         137    1         0     7
## 5                   0    327000                2.7         116    0         0     8
##   DEATH_EVENT
## 1           1
## 2           1
## 3           1
## 4           1
## 5           1
```

6 ANALYSE DESCRIPTIVE

6.1 Tableau de statistiques descriptives

```
stargazer(HeartFailure, type = "text", out = "Data_output/tab1_stats.txt")
```

- 1 PRESENTATON DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
##
## =====
## Statistic          N      Mean      St. Dev.      Min      Max
## -----
## age                299    60.834     11.895     40.000     95.000
## anaemia            299      0.431      0.496        0         1
## creatinine_phosphokinase 299   581.839   970.288      23       7,861
## diabetes           299      0.418      0.494        0         1
## ejection_fraction  299    38.084     11.835      14        80
## high_blood_pressure 299      0.351      0.478        0         1
## platelets          299 263,358.000 97,804.240 25,100.000 850,000.000
## serum_creatinine    299      1.394      1.035      0.500      9.400
## serum_sodium        299    136.625     4.412     113       148
## sex                 299      0.649      0.478        0         1
## smoking             299      0.321      0.468        0         1
## time                299    130.261     77.614        4       285
## DEATH_EVENT         299      0.321      0.468        0         1
## -----
```

6.1.1 Commentaire :

La base de données contient 299 observations. Il est important de souligner qu'il n'y a 0 valeur manquante. Les variables sont toutes numériques (continue, discrète ou binaire). Les variances sont très différentes d'une variables à l'autre.

On remarque que l'étude porte sur des patients âgés de 40 à 95 ans ce qui semble logique car les insuffisances cardiaques atteignent plus les personnes âgées. Dans notre cas, la plupart des patients ont environ 61 ans.

Plus de la moitié des patients ne sont pas anémiés (170 contre 129 patient anémiés). 41.8% des patients déclarent avoir le diabète et ceux souffrant d'hypertension représentent environ 35%.

La plupart des patient ont déclaré qu'à chaque contraction, environ 38% de sang quittent leurs coeurs.

Les femmes sont les plus représentées (65%). 32% des patients fumaient encore et 32% sont morts au cours de la période de suivi.

On remarque également qu'il y'a une disproportionnalité des valeurs des variables, ce qui pourrait influencer nos résultats des méthodes de scoring qui seront appliquées

6.2 Nuages de points

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM


```
# Transformation tibble
HeartFailure_tibble <- as_tibble(HeartFailure)

# Sélection des variables à comparer
vars <- c("platelets", "age", "serum_creatinine", "serum_sodium", "creatinine_phosphokinase", "ejection_fraction")

# Transformation en format tidy pour pouvoir juxtaposer les nuages de points
HeartFailure_long <- HeartFailure_tibble %>%
  dplyr::select(all_of(vars), time, DEATH_EVENT) %>%
  pivot_longer(cols = all_of(vars), names_to = "Variable", values_to = "Valeur")

# Nuages de points juxtaposés
ggplot(HeartFailure_long, aes(x = Valeur, y = time, color = factor(DEATH_EVENT))) +
  geom_point(alpha = 0.6) +
  facet_wrap(~ Variable, scales = "free_x") + # un nuage pour chaque variable
  labs(x = "Valeur", y = "période de suivi", color = "Death Event") +
  theme_minimal()
```

- 1 PRESENTATON DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM



```
# ggsave("data_output/im1_scatterplots.png")
```

6.2.1 Commentaire :

Sur tous les panneaux, l'axe vertical correspond à la période de suivi (time). Les points bleus (patients décédés) sont très majoritairement concentrés en bas du graphique, alors que les points rouges (survivants) s'étendent beaucoup plus vers le haut.

Par conséquent, on peut observer que les patients qui décèdent durant la période de suivi médicale ont le plus souvent un âge relativement avancé, un niveau de créatine phosphokinase inférieur à 2000 mcg/L, un niveau de créatine sérique très faible (inférieur à 2.5 mg/dL) et un niveau de serum sodium important (supérieur à 130 mEq/L)

6.3 Matrice de corrélation

```
cor_matrix <- round(cor(HeartFailure, method = "pearson", use = "complete.obs"),3)
cor_plot <- ggcorrplot(corr = cor_matrix,
                      hc.order = TRUE,
                      type = "full",
                      lab_size = 4,
                      colors = c("#E46726", "white", "#6D9EC1"),
                      title = "Matrice de corrélation",
                      lab = TRUE,
                      ggtheme = )

cor_plot
```

- 1 PRESENTATION DE LA
BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU
REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA
BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA
BASE DE DONNEES :
- 8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE
DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN


11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

Heart Failure Prevision



7 PREPARATION DE LA BASE DE DONNEES

:

```
# Critère de séparation : Méthode train test split
set.seed(123)
idx_train <- sample(nrow(HeartFailure), size = floor(0.7 * nrow(HeartFailure)))
length(idx_train)
```

1 PRESENTATON DE LA BASE DE DONNEES
2 OBJECTIF
3 ORGANISATION DU REPERTOIRE DE TRAVAIL
4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
5 CHARGEMENT DE LA BASE DE DONNES
6 ANALYSE DESCRIPTIVE
7 PREPARATION DE LA BASE DE DONNEES :
8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
9 METHODE DE KMEANS
10 METHODE KNN
11 ANALYSE DISCRIMINANTE LINEAIRE
12 ARBRE DE DECISION
13 RANDOM FOREST
14 SVM

[1] 209

Base d'entrainement

```
HeartFailure_Train <- HeartFailure[idx_train, ]
HeartFailure_Train_labels <- HeartFailure_Train$DEATH_EVENT
HeartFailure_Train_no_death <- subset(HeartFailure_Train, select=-DEATH_EVENT)
HeartFailure_Train |> head(5)
```

```
##      age anaemia creatinine_phosphokinase diabetes ejection_fraction
## 179   63      1              122          1             60
## 14    50      1              168          0             38
## 195   45      0              582          0             20
## 118   85      1              102          0             60
## 229   65      0               56          0             25
##      high_blood_pressure platelets serum_creatinine serum_sodium sex smoking
## 179                0    267000              1.2          145   1      0
## 14                 1    276000              1.1          137   1      0
## 195                1    126000              1.6          135   1      0
## 118                0    507000              3.2          138   0      0
## 229                0    237000              5.0          130   0      0
##      time DEATH_EVENT
## 179   147           0
## 14     11           1
## 195   180           1
## 118    94           0
## 229   207           0
```

Base test

```
HeartFailure_Test <- HeartFailure[-idx_train, ]
HeartFailure_Test_labels <- HeartFailure_Test$DEATH_EVENT
HeartFailure_Test_no_death <- subset(HeartFailure_Test, select=-DEATH_EVENT)
HeartFailure_Test |> head(5)
```

- 1 PRESENTATON DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
##      age anaemia creatinine_phosphokinase diabetes ejection_fraction
## 2      55         0                        7861         0             38
## 3      65         0                        146         0             20
## 8      60         1                        315         1             60
## 12     62         0                        231         0             25
## 15     49         1                         80         0             30
##      high_blood_pressure platelets serum_creatinine serum_sodium sex smoking time
## 2                                0    263358                1.1        136    1         0     6
## 3                                0    162000                1.3        129    1         1     7
## 8                                0    454000                1.1        131    1         1    10
## 12                               1    253000                0.9        140    1         1    10
## 15                               1    427000                1.0        138    0         0    12
##      DEATH_EVENT
## 2                1
## 3                1
## 8                1
## 12               1
## 15               0
```

7.1 Affichage des modalités

```
table(HeartFailure_Train_labels)
```

```
## HeartFailure_Train_labels
##      0      1
## 142    67
```

```
cat("\n")
```

```
table(HeartFailure_Test_labels)
```

1 PRESENTATION DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
## HeartFailure_Test_labels
## 0 1
## 61 29
```

La base de données a été séparée en deux bases. La première base de données est la base de données d'entraînement à partir de laquelle les algorithmes seront entraînés. La deuxième base de données quant à elle sera utilisée pour évaluer les capacités prédictives des algorithmes sur nouvelles données.

8 CLASSIFICATION ASCENDANTE HIERARCHIQUE

8.1 Standardisation des données

```
col_scale <- c("age", "creatinine_phosphokinase", "ejection_fraction", "platelets", "serum_creatinine", "serum_sodium", "time")

# Création des variables standardisées
HeartFailure_Train_no_death_Scaled <- HeartFailure_Train_no_death

HeartFailure_Train_no_death_Scaled[col_scale] <- scale(HeartFailure_Train_no_death_Scaled[col_scale], center = TRUE, scale = TRUE)

HeartFailure_Train_no_death_Scaled |> head(5)
```

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
##          age anaemia creatinine_phosphokinase diabetes ejection_fraction
## 179  0.2106596      1          -0.48097968      1      1.96452699
## 14  -0.8837229      1          -0.43451480      0      0.01862111
## 195 -1.3046392      0          -0.01633085      0     -1.57348370
## 118  2.0626914      1          -0.50118180      0      1.96452699
## 229  0.3790261      0          -0.54764668      0     -1.13123236
##      high_blood_pressure  platelets serum_creatinine serum_sodium sex smoking
## 179                      0 -0.01655170     -0.2098185  1.87042421  1      0
## 14                      1  0.07112762     -0.2985699  0.08438807  1      0
## 195                      1 -1.39019439      0.1451871 -0.36212096  1      0
## 118                      0  2.32156352      1.5652096  0.30764259  0      0
## 229                      0 -0.30881610      3.1627350 -1.47839355  0      0
##              time
## 179  0.2389491
## 14  -1.5056923
## 195  0.6622812
## 118 -0.4409479
## 229  1.0086438
```

```
# Création du fichier données finales
#write.csv(HeartFailure_Train_no_death_Scaled_df, file = #"data_ouput/df3_HeartFailure_Train_no_d
eath_Scaled_df.csv", row.names = FALSE)
```

8.2 Vérification des données standardisées

```
stargazer(HeartFailure_Train_no_death_Scaled, type = "text")
```

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
##
## =====
## Statistic          N   Mean  St. Dev.  Min    Max
## -----
## age                209 -0.000   1.000   -1.726  2.905
## anaemia            209  0.455   0.499     0      1
## creatinine_phosphokinase 209 -0.000   1.000   -0.581  7.176
## diabetes           209  0.426   0.496     0      1
## ejection_fraction  209 -0.000   1.000   -2.016  2.849
## high_blood_pressure 209  0.368   0.484     0      1
## platelets          209 -0.000   1.000   -2.160  5.663
## serum_creatinine    209 -0.000   1.000   -0.742  7.068
## serum_sodium        209  0.000   1.000   -5.274  2.540
## sex                209  0.651   0.478     0      1
## smoking             209  0.330   0.471     0      1
## time               209 -0.000   1.000   -1.595  1.945
## -----
```

On remarque bien que les moyennes et les écart-types sont respectivement aux alentours de 0 et de

8.3 CLASSIFICATION ASCENDANTE HIERARCHIQUE : Critère Linkage Complete

```
# sauvegarder de l'image
#png("data_output/im3_dendo1.png")

# Dissimilarity matrix
d = dist(HeartFailure_Train_no_death_Scaled, method = "euclidean")

# Hierarchical clustering using Complete Linkage
hc1 <- hclust(d, method = "complete" )

fviz_dend(hc1, k = 2, cex = 0.6, k_colors = c("#00AFBB", "#E7B800"),
          color_labels_by_k = TRUE, ggtheme = theme_minimal())
```

1 PRESENTATION DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN


11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
## Warning: The `scale` argument of `guides()` cannot be `FALSE`. Use "none" instead as
## of ggplot2 3.3.4.
## i The deprecated feature was likely used in the factoextra package.
## Please report the issue at <https://github.com/kassambara/factoextra/issues>.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```



- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
#dev.off()
```

```
# # Plot the obtained dendrogram
```

```
# plot(hc1, cex = 0.6, hang = -1) # hang : pour mettre Les étiquettes à partir de 0
```

```
# plot(hc1, cex = 0.6, hang = -1) # hang : pour mettre Les étiquettes à partir de 0
```

Cette classification ascendante hiérarchique (CAH) utilise les critères de distance euclidienne et de saut complet. Ces critères correspondent à la distance entre les individus pour le premier et les classes pour le second. Ces distances permettent de regrouper des individus qui se ressemblent en formant des classes ou des clusters. Plus la variance au sein des classes est faible, plus les individus se ressemblent. De plus, plus la variance entre les classes est forte, plus les individus sont différents d'une classe à l'autre. L'objectif est par conséquent d'atteindre la classification optimale, c'est à dire, celle qui minimise la variance intra-groupe et qui maximise la variance inter-groupe et de le présenter sous la forme d'un dendrogramme.

Ainsi, on peut remarquer, que l'Algorithme de CAH déployé a permis d'obtenir deux groupes disproportionnés en nombre d'individus.

8.4 CLASSIFICATION ASCENDANTE HIERARCHIQUE : distance de Ward

```
# sauvegarder de L'image
```


```
#png("data_output/im4_dendo2.png")
```

```
# Classification Ascendante Hierarchique en utilisant Le critère de Ward
```

```
hc2 <- hclust(d, method = "ward.D2" )
```

```
fviz_dend(hc2, k = 2, cex = 0.6, k_colors = c("#00AFBB", "#E7B800"),
          color_labels_by_k = TRUE, ggtheme = theme_minimal())
```

Cluster Dendrogram



1 PRESENTATION DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
# # Dendogramme
# plot(hc2, cex = 0.6, hang = -1)
#
# # Diviser le dendogramme en 2 groupes
# sub_grp <- cutree(hc2, k = 2)
#
# # Paramétrage
# plot(hc2, cex = 0.6)
# rect.hclust(hc2, k = 2, border = 2:3)

#dev.off()

# # Plot the obtained dendrogram
# plot(hc2, cex = 0.6, hang = -1)
#
# # We can cut the tree into 2 groups
# sub_grp <- cutree(hc2, k = 2)
# #
# plot(hc2, cex = 0.6)
# rect.hclust(hc2, k = 2, border = 2:3)
```

C'est dans le but d'améliorer la classification, qu'on va utiliser le critère de Ward comme critère de distance entre les classes. Ce dernier est généralement plus robuste car il prend en compte la taille des cluster dans le calcul de la distance. Ainsi, on peut observer qu'avec la distance de WARD, on arrive à mieux distinguer les groupes. On peut distinguer 2 à 3 groupes qui se forment.

8.5 Evaluation des résultats de la CAH

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
# Valeurs prédites : Clustering selon la cah
cah_train_prediction <- cutree(hc2, 2) # coder en 1 et 2

# Création des variables labels true et labels predict
HeartFailure_Train_no_death_Scaled$cluster_pred <- ifelse(cah_train_prediction==1,0,1)
HeartFailure_Train_no_death_Scaled$cluster_true <- HeartFailure_Train_labels

# Matrice de confusion cah
confusion_matrix_cah <- table(HeartFailure_Train_no_death_Scaled$cluster_pred, HeartFailure_Train_no_death_Scaled$cluster_true)
print(confusion_matrix_cah)
```

```
##
##      0  1
##  0 82 55
##  1 60 12
```

```
# accuracy
accuracy_cah <- sum(diag(confusion_matrix_cah)) / sum(confusion_matrix_cah)
cat("accuracy in cah is : ", accuracy_cah)
```

```
## accuracy in cah is : 0.4497608
```

Notre modèle arrive à classer 82 individus comme survivants et qui ont bien survécu. Cependant, il déclare 55 survivants qui en réalité sont décédés.

Pour les non survivants, notre modèle catégorise 60 non survivants qui en réalité ont survécu et il arrive à classer 11 non survivants qui sont bien décédés.

Ces résultats sont logiques car base contient beaucoup plus de survivants que d'individus décédés. Ainsi, notre modèle est mieux entraîné sur cette catégories d'individus, ce qui explique pourquoi il arrive à mieux catégoriser les survivant.

En général, notre modèle arrive à être précis à 44,48%

9 METHODE DE KMEANS

Spécifier Le nombre de clusters

```
kMeans_ncluster <- 2
```

Appliquer L'algorithme K-Médian sur L'ensemble de données d'entraînement

```
kMeans_result <- kmeans(HeartFailure_Train_no_death, centers = kMeans_ncluster, nstart = 57)  
kMeans_result
```

- 1 PRESENTATON DE LA
BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU
REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA
BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA
BASE DE DONNEES :
- 8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE
DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

1 PRESENTATION DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
## K-means clustering with 2 clusters of sizes 166, 43
##
## Cluster means:
##      age  anaemia creatinine_phosphokinase  diabetes ejection_fraction
## 1 60.50602 0.4518072                578.4880 0.4036145          37.74096
## 2 60.46512 0.4651163                674.1395 0.5116279          37.97674
##  high_blood_pressure platelets serum_creatinine serum_sodium      sex
## 1              0.3614458 230946.3          1.410723   136.5181 0.6626506
## 2              0.3953488 414441.9          1.535581   137.0233 0.6046512
##      smoking      time
## 1 0.3253012 127.4337
## 2 0.3488372 132.0000
##
## Clustering vector:
## 179  14 195 118 229 244 298 153  90  91 256 197 290 137  26  7 286 254 211  78
##   1  1  1  2  1  1  1  1  1  1  2  1  2  1  1  1  2  1  2  1
##  81  43 143  32 109 263  23 135 224 166 217  69  72  76  63 141 210 292  41 291
##   1  1  2  2  1  1  1  1  1  1  2  1  1  1  1  1  1  1  1  1
## 223  16 116  94  6 235 200  86 252  39 159 240 209 296  50 241  34  4  13 268
##   2  1  1  1  1  1  1  2  1  1  1  1  1  1  2  2  1  1  1  1
## 127 262  52  22  89 160  25 215  35 168 112  30 140 249 121 110 158  64 142 199
##   1  1  2  1  1  2  1  1  1  1  1  1  1  1  2  1  2  2  2  1
##  67 151 122  79  85 165 136  51  74 178 106  98 281 239 204 174  17 190  46  54
##   1  1  1  1  1  2  1  1  1  1  2  1  1  1  1  1  1  1  1  2
## 163 271 289 216  24 113 107 272 218 154 102 234 192 155 170  5  70 258 297 276
##   2  1  1  1  2  1  1  1  1  1  1  2  1  1  1  2  2  1  2  2
##  21  55  75 164  83 250 253 283  48  77 175 111 205  1 228 288 182  88 173  20
##   1  1  1  1  1  1  1  1  2  1  1  1  1  1  1  2  1  1  1  1
## 104  93 237 108 236  42  59  84  11 225 213 201 232 275 193 185  36 221 220 125
##   1  1  1  1  2  1  1  1  2  2  2  1  1  1  1  1  1  1  2  1
##  33  40  10 227  9 284  61 265 161 285 139  57 149  29 115 172  53 131 144 145
##   1  2  2  1  1  1  2  1  1  1  1  1  1  1  2  2  1  1  1  2
## 191 233 157 130 134 246  87 260 180 152 181 128  73 105 101 273 293 255 287 270
##   2  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  2  1  1  1
## 295  58 279 126 257  27 147 206  60
##   1  1  1  1  1  1  1  2  1
##
## Within cluster sum of squares by cluster:
```

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
## [1] 533461925225 508349786700
## (between_SS / total_SS = 52.5 %)
##
## Available components:
##
## [1] "cluster"      "centers"      "totss"        "withinss"     "tot.withinss"
## [6] "betweenss"    "size"         "iter"         "ifault"
```

Ici, on fixe le nombre de cluster égal à 2 car on connaît d'avantage le nombre de classe existante. Le ratio $\text{between_SS} / \text{total_SS}$ mesure la part de la variabilité totale expliquée par la le clustering. Une valeur élevée indique que les groupes obtenus sont bien séparés et captent une part importante de nos données.

On remarque que le ratio $\text{between_SS} / \text{total_SS} = 52.5 \%$. Ce qui implique que 52.5 % de la variabilité totale des données est expliquée par la séparation en deux clusters.

Nous allons comparer ce ration en augmentant le nombre de cluster (k à 3)

```
# Spécifier Le nombre de clusters
kMeans_ncluster <- 3

# Appliquer L'algorithme K-Médian sur L'ensemble de données d'entraînement
kMeans_result_k3 <- kmeans(HeartFailure_Train_no_death, centers = kMeans_ncluster, nstart = 57)
kMeans_result_k3
```

- 1 PRESENTATON DE LA
BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU
REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA
BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA
BASE DE DONNEES :
- 8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE
DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
## K-means clustering with 3 clusters of sizes 110, 88, 11
##
## Cluster means:
##      age  anaemia creatinine_phosphokinase  diabetes ejection_fraction
## 1 60.05455 0.4363636                    592.1091 0.4181818          38.52727
## 2 60.81818 0.5000000                    617.6932 0.4090909          36.44318
## 3 62.36364 0.2727273                    502.5455 0.6363636          41.18182
##  high_blood_pressure platelets serum_creatinine serum_sodium      sex
## 1           0.4090909 302728.1           1.367909   136.5818 0.6272727
## 2           0.3295455 189556.8           1.530795   136.5568 0.6931818
## 3           0.2727273 561545.5           1.366364   137.5455 0.5454545
##      smoking      time
## 1 0.3363636 127.1545
## 2 0.3068182 127.3409
## 3 0.4545455 148.8182
##
## Clustering vector:
## 179 14 195 118 229 244 298 153 90 91 256 197 290 137 26 7 286 254 211 78
## 1 1 2 3 2 2 2 2 2 1 1 1 1 2 2 2 1 2 1 2
## 81 43 143 32 109 263 23 135 224 166 217 69 72 76 63 141 210 292 41 291
## 1 2 1 1 1 2 1 2 2 2 1 2 2 2 1 1 1 2 1 2
## 223 16 116 94 6 235 200 86 252 39 159 240 209 296 50 241 34 4 13 268
## 1 2 2 2 2 1 1 1 2 1 2 1 1 1 1 3 1 2 2 2
## 127 262 52 22 89 160 25 215 35 168 112 30 140 249 121 110 158 64 142 199
## 1 1 1 1 2 1 1 1 2 2 2 2 2 1 2 3 1 1 1 1
## 67 151 122 79 85 165 136 51 74 178 106 98 281 239 204 174 17 190 46 54
## 2 2 2 1 1 1 1 2 2 2 3 1 2 1 2 2 1 1 1 1
## 163 271 289 216 24 113 107 272 218 154 102 234 192 155 170 5 70 258 297 276
## 3 1 1 2 1 1 1 2 2 1 1 1 1 2 1 1 3 1 3 1
## 21 55 75 164 83 250 253 283 48 77 175 111 205 1 228 288 182 88 173 20
## 1 1 1 2 2 2 1 2 3 1 1 1 1 1 2 3 2 1 2 2
## 104 93 237 108 236 42 59 84 11 225 213 201 232 275 193 185 36 221 220 125
## 2 1 1 2 1 2 1 2 1 3 3 2 2 2 1 2 2 1 1 2
## 33 40 10 227 9 284 61 265 161 285 139 57 149 29 115 172 53 131 144 145
## 1 1 1 2 1 1 1 2 2 1 2 2 2 2 1 1 1 1 2 1
## 191 233 157 130 134 246 87 260 180 152 181 128 73 105 101 273 293 255 287 270
## 1 1 1 2 1 1 2 1 1 2 1 1 2 1 1 2 1 1 1 2
## 295 58 279 126 257 27 147 206 60
```


- 1 PRESENTATON DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
## 2 2 2 2 1 2 2 1 1
##
## Within cluster sum of squares by cluster:
## [1] 224023582001 183311135045 162519889635
## (between_SS / total_SS = 74.0 %)
##
## Available components:
##
## [1] "cluster"      "centers"      "totss"        "withinss"     "tot.withinss"
## [6] "betweenss"    "size"         "iter"         "ifault"
```

Avec un $k=3$, on remarque que le ratio $\text{between_SS} / \text{total_SS}$ passe de 52.5 % à 74.0 %, ce qui constitue une grande amélioration. Cependant, vu qu'on connaît déjà le nombre de classe (2 pour mort ou survi), nous allons retenir un $k=2$

Pour confirmer le nombre de K utilisé, on va utiliser la méthode du coude

9.1 Méthode du Coude


```
# Définir Le nombre maximum de clusters à tester :10 c'est bien étant donné Le nbr d'obsr que vous avons
max_clusters <- 10

# Stocker Les valeurs de WCSS (Within-Cluster Sum of Squares) pour chaque nombre de clusters
wcss_values <- numeric(max_clusters)

# Calculer WCSS pour chaque nombre de clusters
for (k in 1:max_clusters) {
  kmeans_result_coude <- kmeans(HeartFailure_Train_no_death, centers = k)
  wcss_values[k] <- kmeans_result_coude$tot.withinss
}

# Créer un graphique pour visualiser Les valeurs de WCSS
plot(1:max_clusters, wcss_values, type = "b", pch = 19, frame = FALSE,
     xlab = "Nombre de clusters", ylab = "WCSS")
```

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM



```
#ggsave("data_output/im5_CoudeGraph.png")
```

On remarque qu'il y a une déclinaison (aussi appelée saut) importante de la courbe en 2, ce qui confirme qu'on a effectivement 2 groupes.

9.2 Prévision et Evaluation kMeans

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
#kMeans sur Les données d'entrainement
kmean_test_prediction <- cl_predict(kMeans_result, newdata = HeartFailure_Test_no_death)

#Prédire les clusters pour les données de test
kmean_test_prediction_recode <- ifelse(kmean_test_prediction==1,1,0)

#Créer la matrice de confusion entre les clusters prédits et les vraies étiquettes
confusion_matrix_kMeans <- table(kmean_test_prediction_recode, HeartFailure_Test_labels)
print(confusion_matrix_kMeans)
```

```
##               HeartFailure_Test_labels
## kmean_test_prediction_recode  0  1
##                               0 11  5
##                               1 50 24
```

```
# Calculer la précision en utilisant la matrice de confusion
accuracy_kMeans <- sum(diag(confusion_matrix_kMeans)) / sum(confusion_matrix_kMeans)
cat("accuracy kMeans is : ", accuracy_kMeans)
```

```
## accuracy kMeans is :  0.3888889
```

Notre modèle arrive à classer 11 individus comme survivants et qui ont bien survécu. Cependant, il déclare 5 survivants qui en réalité sont décédés.

Pour les non survivants, notre modèle catégorise 50 non survivants qui en réalité ont survécu et il arrive à classer 24 non survivants qui sont bien décédés.

En général, notre modèle arrive à être précis à 38,89%

10 METHODE KNN

1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
knn_nb_cluster <- 2
knn_result <- knn(HeartFailure_Train_no_death, HeartFailure_Test_no_death, HeartFailure_Train_labels, knn_nb_cluster)
knn_result
```

```
## [1] 1 0 0 0 0 0 0 0 1 0 1 0 1 1 0 1 0 0 0 0 0 0 0 0 1 1 0 0 1 1 0 1 1 0 0 1 0 0
## [39] 0 0 1 0 0 1 0 1 1 0 1 1 1 0 1 1 0 0 0 0 0 0 0 1 1 0 0 1 0 1 1 0 1 0 0 0 1 1 0
## [77] 0 0 0 1 0 0 0 0 0 0 1 1 1 0 1
## Levels: 0 1
```

10.1 MATRICE DE CONFUSION : KNN ALGORITHM

```
confusion_matrix_knn <- confusionMatrix(table(knn_result, HeartFailure_Test_labels))
print(confusion_matrix_knn)
```

1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
## Confusion Matrix and Statistics
##
##           HeartFailure_Test_labels
## knn_result  0  1
##           0 38 17
##           1 23 12
##
##           Accuracy : 0.5556
##           95% CI : (0.447, 0.6604)
##           No Information Rate : 0.6778
##           P-Value [Acc > NIR] : 0.9944
##
##           Kappa : 0.0349
##
##           Mcnemar's Test P-Value : 0.4292
##
##           Sensitivity : 0.6230
##           Specificity : 0.4138
##           Pos Pred Value : 0.6909
##           Neg Pred Value : 0.3429
##           Prevalence : 0.6778
##           Detection Rate : 0.4222
##           Detection Prevalence : 0.6111
##           Balanced Accuracy : 0.5184
##
##           'Positive' Class : 0
##
```

```
#accuracy_knn <- sum(diag(confusion_matrix_knn)) / sum(confusion_matrix_knn)
#cat("accuracy knn is : ", accuracy_knn)

# Accuracy
accuracy_knn <- confusion_matrix_knn$overall["Accuracy"]
cat("Accuracy KNN is :", accuracy_knn)
```

1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
## Accuracy KNN is : 0.5555556
```

En général, notre modèle arrive à être précis à 55,56%, ce qui constitue une amélioration par rapports au modèles précédents.

11 ANALYSE DISCRIMINANTE LINEAIRE

```
lda_model <- lda(DEATH_EVENT ~., data = HeartFailure_Train)
lda_model
```

1 PRESENTATION DE LA BASE DE DONNEES
2 OBJECTIF
3 ORGANISATION DU REPERTOIRE DE TRAVAIL
4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
5 CHARGEMENT DE LA BASE DE DONNES
6 ANALYSE DESCRIPTIVE
7 PREPARATION DE LA BASE DE DONNEES :
8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
9 METHODE DE KMEANS
10 METHODE KNN
11 ANALYSE DISCRIMINANTE LINEAIRE
12 ARBRE DE DECISION
13 RANDOM FOREST
14 SVM

```
## Call:
## lda(DEATH_EVENT ~ ., data = HeartFailure_Train)
##
## Prior probabilities of groups:
##      0      1
## 0.6794258 0.3205742
##
## Group means:
##      age  anaemia creatinine_phosphokinase  diabetes ejection_fraction
## 0 58.49296 0.4295775                582.2324 0.4154930                40.04225
## 1 64.74627 0.5074627                631.9403 0.4477612                33.01493
##  high_blood_pressure platelets serum_creatinine serum_sodium      sex
## 0                0.3380282 274415.1            1.189859    137.1408 0.6549296
## 1                0.4328358 256584.3            1.958955    135.5224 0.6417910
##      smoking      time
## 0 0.3309859 159.16901
## 1 0.3283582  63.10448
##
## Coefficients of linear discriminants:
##                                LD1
## age                2.422686e-02
## anaemia            5.041868e-02
## creatinine_phosphokinase 1.240082e-04
## diabetes            2.495482e-01
## ejection_fraction    -4.892623e-02
## high_blood_pressure    7.835276e-02
## platelets           -6.347819e-07
## serum_creatinine      3.943616e-01
## serum_sodium         -1.366975e-02
## sex                 -2.233708e-01
## smoking             -7.916041e-02
## time                -1.234870e-02
```

Dans le train data, environ 68 % des patients ne décèdent pas contre 32 % qui décèdent. Les patients décédés (DEATH_EVENT = 1) : - sont en moyenne plus âgés (65 contre 58) : Normal car les plus âgés ont un organisme plus fragile; - ont en moyenne une fraction d'éjection plus faible (33 contre 40); - en moyenne créatinine beaucoup

plus élevée (1.96 contre 1.19); - en moyenne un temps de suivi beaucoup plus court (63 contre 159) : Normal car ils sont décédés bien avant.

L'analyse discriminante sépare principalement les patients en deux groupe, ce qui justifie le fait d'avoir un seul axe discriminant.

11.1 Evaluation : Analyse Discriminante Linéaire

```
# déploiement du modèle d'analyse discriminante  
lda_test_prediction <- predict(lda_model, newdata = HeartFailure_Test)  
lda_test_prediction
```

- 1 PRESENTATON DE LA
BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU
REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA
BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA
BASE DE DONNEES :
- 8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE
DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
## $class
## [1] 1 1 0 1 1 1 1 1 1 1 1 0 1 1 1 1 0 1 1 0 0 0 0 0 1 1 0 1 0 0 0 1 0 0 0 1
## [39] 0 1 0 0 0 1 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [77] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## Levels: 0 1
##
## $posterior
##           0           1
## 2  0.078466934 0.9215330659
## 3  0.042887707 0.9571122931
## 8  0.762158978 0.2378410225
## 12 0.140282241 0.8597177590
## 15 0.229405903 0.7705940968
## 18 0.078906775 0.9210932249
## 19 0.053129937 0.9468700626
## 28 0.336288021 0.6637119789
## 31 0.034376794 0.9656232057
## 37 0.259582566 0.7404174342
## 38 0.261229057 0.7387709429
## 44 0.459040705 0.5409592955
## 45 0.736395137 0.2636048633
## 47 0.219295023 0.7807049773
## 49 0.002630475 0.9973695250
## 56 0.051192385 0.9488076147
## 62 0.372132125 0.6278678750
## 65 0.993528548 0.0064714515
## 66 0.057314281 0.9426857188
## 68 0.292326408 0.7076735923
## 71 0.931909870 0.0680901299
## 80 0.832217325 0.1677826753
## 82 0.868308563 0.1316914374
## 92 0.760938321 0.2390616792
## 95 0.676621517 0.3233784834
## 96 0.967668705 0.0323312949
## 97 0.205110039 0.7948899609
## 99 0.218598430 0.7814015702
## 100 0.581297167 0.4187028330
## 103 0.278324778 0.7216752217
```

- 1 PRESENTATON DE LA
BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU
REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA
BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA
BASE DE DONNEES :
- 8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE
DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

##	114	0.924050127	0.0759498735
##	117	0.942071592	0.0579284080
##	119	0.916728394	0.0832716061
##	120	0.267815934	0.7321840663
##	123	0.708899774	0.2911002259
##	124	0.525042661	0.4749573385
##	129	0.764406396	0.2355936042
##	132	0.072831858	0.9271681416
##	133	0.869344026	0.1306559741
##	138	0.264166310	0.7358336897
##	146	0.903762440	0.0962375601
##	148	0.975065813	0.0249341867
##	150	0.754033038	0.2459669621
##	156	0.432582092	0.5674179077
##	162	0.946368953	0.0536310473
##	167	0.995345695	0.0046543045
##	169	0.839341411	0.1606585885
##	171	0.882996583	0.1170034170
##	176	0.995001847	0.0049981535
##	177	0.904755529	0.0952444706
##	183	0.720665633	0.2793343667
##	184	0.742862829	0.2571371715
##	186	0.860652730	0.1393472703
##	187	0.991653067	0.0083469327
##	188	0.568975445	0.4310245550
##	189	0.915081148	0.0849188516
##	194	0.844887325	0.1551126747
##	196	0.950996374	0.0490036263
##	198	0.929428708	0.0705712922
##	202	0.998093529	0.0019064714
##	203	0.996001525	0.0039984750
##	207	0.991831120	0.0081688796
##	208	0.932570695	0.0674293047
##	212	0.999035031	0.0009649686
##	214	0.874737319	0.1252626811
##	219	0.923853548	0.0761464522
##	222	0.995661598	0.0043384018
##	226	0.983484383	0.0165156168

- 1 PRESENTATON DE LA
BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU
REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA
BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA
BASE DE DONNEES :
- 8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE
DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
## 230 0.862278654 0.1377213462
## 231 0.887621007 0.1123789934
## 238 0.941301733 0.0586982670
## 242 0.940793795 0.0592062052
## 243 0.995088707 0.0049112926
## 245 0.971683433 0.0283165675
## 247 0.956802669 0.0431973314
## 248 0.870503940 0.1294960605
## 251 0.976569765 0.0234302349
## 259 0.980780186 0.0192198136
## 261 0.995978936 0.0040210636
## 264 0.997374170 0.0026258301
## 266 0.996919473 0.0030805271
## 267 0.946959950 0.0530400504
## 269 0.994790923 0.0052090775
## 274 0.998819578 0.0011804222
## 277 0.984719803 0.0152801969
## 278 0.981993113 0.0180068868
## 280 0.990914438 0.0090855617
## 282 0.973486122 0.0265138783
## 294 0.993831682 0.0061683176
## 299 0.999397368 0.0006026320
##
## $x
##          LD1
## 2      1.93759978
## 3      2.25120911
## 8      0.16533575
## 12     1.61986771
## 15     1.32613832
## 18     1.93463591
## 19     2.14133680
## 28     1.06635551
## 31     2.36359347
## 37     1.24625288
## 38     1.24207662
## 44     0.81444422
## 45     0.23237713
```

- 1 PRESENTATON DE LA
BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU
REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA
BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA
BASE DE DONNEES :
- 8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE
DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

## 47	1.35452576
## 49	3.63496655
## 56	2.16048334
## 62	0.98975774
## 65	-1.72485192
## 66	2.10213982
## 68	1.16612425
## 71	-0.54390476
## 80	-0.04807930
## 82	-0.18713863
## 92	0.16861948
## 95	0.37356903
## 96	-0.92613777
## 97	1.39598918
## 99	1.35651567
## 100	0.57394902
## 103	1.19967230
## 114	-0.48640198
## 117	-0.62815745
## 119	-0.43755651
## 120	1.22553659
## 123	0.29943413
## 124	0.68525362
## 129	0.15925940
## 132	1.97698333
## 133	-0.19157705
## 138	1.23466839
## 146	-0.35990489
## 148	-1.05677012
## 150	0.18698335
## 156	0.86677259
## 162	-0.66803483
## 167	-1.88676060
## 169	-0.07343868
## 171	-0.25310312
## 176	-1.85177292
## 177	-0.36550856
## 183	0.27123783

1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
## 184 0.21597004
## 186 -0.15520799
## 187 -1.59960676
## 188 0.59858371
## 189 -0.42710881
## 194 -0.09381702
## 196 -0.71449757
## 198 -0.52511813
## 202 -2.32411925
## 203 -1.96127666
## 207 -1.61022785
## 208 -0.54901524
## 212 -2.65721152
## 214 -0.21519124
## 219 -0.48503529
## 222 -1.92125110
## 226 -1.26220237
## 230 -0.16186349
## 231 -0.27535447
## 238 -0.62130866
## 242 -0.61683593
## 243 -1.86037978
## 245 -0.99293088
## 247 -0.77907951
## 248 -0.19658455
## 251 -1.08791432
## 259 -1.18678230
## 261 -1.95851361
## 264 -2.16737474
## 266 -2.08913551
## 267 -0.67375288
## 269 -1.83147726
## 274 -2.55865627
## 277 -1.30079649
## 278 -1.21923062
## 280 -1.55782102
## 282 -1.02596976
```

1 PRESENTATION DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
## 294 -1.74843676
## 299 -2.88737264
```

```
# Matrice de confusion
confusion_matrix_lda <- confusionMatrix(table(lda_test_prediction$class, HeartFailure_Test_label
s))
print(confusion_matrix_lda)
```

```
## Confusion Matrix and Statistics
##
##      HeartFailure_Test_labels
##      0  1
## 0 53 13
## 1  8 16
##
##              Accuracy : 0.7667
##              95% CI : (0.6657, 0.8494)
##      No Information Rate : 0.6778
##      P-Value [Acc > NIR] : 0.04253
##
##              Kappa : 0.4405
##
##  Mcnemar's Test P-Value : 0.38273
##
##              Sensitivity : 0.8689
##              Specificity : 0.5517
##              Pos Pred Value : 0.8030
##              Neg Pred Value : 0.6667
##              Prevalence : 0.6778
##              Detection Rate : 0.5889
##      Detection Prevalence : 0.7333
##              Balanced Accuracy : 0.7103
##
##      'Positive' Class : 0
##
```

1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
# Accuracy
```

```
accuracy_lda <- confusion_matrix_lda$overall["Accuracy"]  
cat("Accuracy LDA is :", accuracy_lda)
```

```
## Accuracy LDA is : 0.7666667
```

En général, notre modèle arrive à être précis à 76,67%, ce qui constitue une amélioration par rapport au modèle précédent.

11.2 Courbe roc pour lda

```
roc_lda <- roc(HeartFailure_Test_labels, as.numeric(lda_test_prediction$class))
```

```
## Setting levels: control = 0, case = 1
```

```
## Setting direction: controls < cases
```

```
auc_lda_val <- auc(roc_lda)  
print(auc_lda_val)
```


```
## Area under the curve: 0.7103
```

```
cat("\n")
```

```
plot(roc_lda, col = "red", lwd = 2, main = "Courbe ROC - LDA")
```

- 1 PRESENTATON DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

Courbe ROC - LDA



On a un auc de 0.7103, ce qui implique que si on prend au hasard un patient décédé et un patient survivant, le modèle a environ 71 % de chances d'attribuer un score de risque plus élevé au patient décédé.

12 ARBRE DE DECISION

```
cart_model <- rpart(DEATH_EVENT ~., data = HeartFailure_Train, method="class", parms=list(split
="gini"))
cart_model
```


1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION


13 RANDOM FOREST

14 SVM

```
## n= 209
##
## node), split, n, loss, yval, (yprob)
##      * denotes terminal node
##
## 1) root 209 67 0 (0.67942584 0.32057416)
##    2) time>=73.5 154 21 0 (0.86363636 0.13636364)
##      4) ejection_fraction>=27.5 131 10 0 (0.92366412 0.07633588) *
##      5) ejection_fraction< 27.5 23 11 0 (0.52173913 0.47826087)
##        10) serum_creatinine< 1.15 10 2 0 (0.80000000 0.20000000) *
##        11) serum_creatinine>=1.15 13 4 1 (0.30769231 0.69230769) *
##    3) time< 73.5 55 9 1 (0.16363636 0.83636364) *
```

```
#jpeg("Data_output/arbre_decision.jpg", width = 1200, height = 800, res = 150)
rpart.plot(cart_model)
```

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM



```
#dev.off()
```

On commence par 100% de notre échantillon. La modalité la plus représentée est 0(survie) et la modalité 1(decès) représente 32% de l'échantillon.

La 1er condition de split est la période de suivi ≥ 74 jours. A droite on a ceux qui ne respectent pas la condition : environ 26% des patients ont été suivis moins de 74 jours, et dans ce groupe la probabilité estimée de décès est d'environ 84%. Les 74% de patients (respectant la 1ère condition de split), ont une probabilité de décès beaucoup plus faible (0.14%).

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

La 2ème condition de split est la fraction d'éjection $\geq 28\%$. Dans la branche gauche on a $\text{time} \geq 74$ et $\text{ejection_fraction} < 28$: environ 63% des patients ayant une période de suivi plus longue et avec un taux d'éjection $\geq 28\%$ ont survécu.

La 3ème condition de split porte sur le taux de créatinine dans le sang $< 1.2\text{mg/dL}$ Branche gauche : $\text{time} \geq 74$ avec $\text{ejection_fraction} \geq 28$ et $\text{serum_creatinine} < 1.2$: proba associée à la survie (0) = 0.20, représentant environ 5% des patients.

Branche droite : $\text{time} \geq 74$ avec $\text{ejection_fraction} \geq 28$ et $\text{serum_creatinine} \geq 1.2$: classe 1 plus représentée avec proba de 0.69 pour 6% des patients. Ici, malgré une fraction d'éjection correcte ($\geq 28\%$), une créatinine élevée est associée à un risque élevé de décès (environ 69%).

12.1 Elagage de l'arbre


```
cart = rpart(DEATH_EVENT ~., data = HeartFailure_Train, method="class", parms=list(split="gini"),
             cp=0)
printcp(cart)
```

```
##
## Classification tree:
## rpart(formula = DEATH_EVENT ~ ., data = HeartFailure_Train, method = "class",
##       parms = list(split = "gini"), cp = 0)
##
## Variables actually used in tree construction:
## [1] ejection_fraction serum_creatinine serum_sodium      time
##
## Root node error: 67/209 = 0.32057
##
## n= 209
##
##          CP nsplit rel error  xerror    xstd
## 1 0.5522388      0   1.00000 1.00000 0.100701
## 2 0.0373134      1   0.44776 0.46269 0.076691
## 3 0.0074627      3   0.37313 0.53731 0.081475
## 4 0.0000000      5   0.35821 0.58209 0.084064
```

En réalité, cet arbre commet un erreur de $67/209 = 0.32057$ (taux d'erreur relatif)

12.2 choix valeur coefficient de pénalisation de la complexité pour élagage

```
cart_model_3f = rpart(DEATH_EVENT ~., data = HeartFailure_Train, method="class", parms=list(split="gini"), control=list(minbucket=30, minsplit=30*2, maxdepth=3))
rpart.plot(cart_model_3f)
```



- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

Avec la complexité on arrive à 2 feuille qui correspond exactement au nombre de groupe de notre variable cible

1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

12.3 Evaluation : Arbre de décision

```
cart_test_prediction <- predict(cart_model, HeartFailure_Test, type="class")
cart_test_prediction
```

```
##      2      3      8     12     15     18     19     28     31     37     38     44     45     47     49     56     62     65     66     68
##      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1
##     71     80     82     92     95     96     97     99    100    103    114    117    119    120    123    124    129    132    133    138
##      1      0      0      0      0      0      1      1      0      0      0      0      0      0      0      0      0      0      0      1
##    146    148    150    156    162    167    169    171    176    177    183    184    186    187    188    189    194    196    198    202
##      0      0      0      1      0      0      0      0      0      0      1      0      0      0      1      0      0      0      0      0
##    203    207    208    212    214    219    222    226    230    231    238    242    243    245    247    248    251    259    261    264
##      0      0      0      0      0      0      0      0      1      0      0      0      0      0      0      1      0      0      0      0
##    266    267    269    274    277    278    280    282    294    299
##      0      1      0      0      0      0      0      0      0      0
## Levels: 0 1
```

```
# Matrice de confusion : CART algorithm
confusion_matrix_cart <- confusionMatrix(table(cart_test_prediction, HeartFailure_Test_labels))
print(confusion_matrix_cart)
```

1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
## Confusion Matrix and Statistics
##
##               HeartFailure_Test_labels
## cart_test_prediction  0  1
##                0  51  9
##                1  10 20
##
##               Accuracy : 0.7889
##               95% CI : (0.6901, 0.8679)
##      No Information Rate : 0.6778
##      P-Value [Acc > NIR] : 0.01376
##
##               Kappa : 0.521
##
##  Mcnemar's Test P-Value : 1.00000
##
##               Sensitivity : 0.8361
##               Specificity : 0.6897
##               Pos Pred Value : 0.8500
##               Neg Pred Value : 0.6667
##               Prevalence : 0.6778
##               Detection Rate : 0.5667
##               Detection Prevalence : 0.6667
##               Balanced Accuracy : 0.7629
##
##               'Positive' Class : 0
##
```

```
# Accuracy
accuracy_cart <- confusion_matrix_cart$overall["Accuracy"]
cat("Accuracy CART is :", accuracy_cart)
```

```
## Accuracy CART is : 0.7888889
```

En général, notre modèle arrive à être précis à 78,89%, ce qui constitue une amélioration par rapport au modèle précédent.

12.4 Courbe de ROC

1 PRESENTATION DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
# Tracer la courbe ROC
```

```
roc_curve_cart <- roc(cart_test_prediction, HeartFailure_Test_labels)
```

```
## Setting levels: control = 0, case = 1
```

```
## Setting direction: controls < cases
```


```
auc_cart_val <- auc(roc_curve_cart)  
print(auc_cart_val)
```

```
## Area under the curve: 0.7583
```

```
plot(roc_curve_cart, main = "Courbe ROC", col = "red", lwd = 2)
```

- 1 PRESENTATON DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

Courbe ROC



On a un auc de 0.7583, ce qui implique que si on prend au hasard un patient décédé et un patient survivant, le modèle a environ 76 % de chances d'attribuer un score de risque plus élevé au patient décédé.

13 RANDOM FOREST

```
library(randomForest)
```

```
## Warning: le package 'randomForest' a été compilé avec la version R 4.5.1
```


1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
## randomForest 4.7-1.2
```

```
## Type rfNews() to see new features/changes/bug fixes.
```

```
##  
## Attachement du package : 'randomForest'
```


```
## L'objet suivant est masqué depuis 'package:dplyr':  
##  
##      combine
```

```
## L'objet suivant est masqué depuis 'package:ggplot2':  
##  
##      margin
```

```
random_forest_result <- randomForest(as.factor(DEATH_EVENT)~.,data=HeartFailure_Train,ntree=500)  
plot(random_forest_result)
```

- 1 PRESENTATON DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

random_forest_result




Variables les plus importants/plus utilisées dans la ségmentation

```
varImpPlot(random_forest_result)
```

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

time
 serum_creatinine
 ejection_fraction
 age
 creatinine_phosphokinase
 platelets
 serum_sodium
 high_blood_pressure
 anaemia
 diabetes
 smoking
 sex

random_forest_result



La forêt aléatoire nous montre les variables les plus important de notre modèle à savoir time, serum_creatine, ejection_fraction, age, platelets

13.1 Evaluation du RAMDON FOREST

```
# Prédiction
random_forest_test_prediction <- predict(random_forest_result,HeartFailure_Test,type="class")

confusion_matrix_random_forest <- random_forest_result$confusion[, -3]
confusion_matrix_random_forest
```

1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
##      0  1
## 0 130 12
## 1  17 50
```

```
#mean(Pima.tr$type!=pred.rf)
```

```
# Accuracy
```

```
accuracy_random_forest <- sum(diag(confusion_matrix_random_forest)) / sum(confusion_matrix_rando
m_forest)
```

```
cat("Accuracy RANDOM FOREST is :", accuracy_random_forest)
```

```
## Accuracy RANDOM FOREST is : 0.861244
```

Notre modèle arrive à classer 128 individus comme survivants et qui ont bien survécu. Cependant, il déclare 14 survivants qui en réalité sont décédés.

Pour les non survivants, notre modèle catégorise 17 non survivants qui en réalité ont survécu et il arrive à classer 50 non survivants qui sont bien décédés.

En général, notre modèle arrive à être précis à 85,16%

13.2 Courbe de ROC

```
roc_curve_random_forest <- roc(as.numeric(random_forest_test_prediction), HeartFailure_Test_label
s)
```

```
## Setting levels: control = 1, case = 2
```

```
## Setting direction: controls < cases
```

```
auc_radom_forest_val <- auc(roc_curve_random_forest)
print(auc_radom_forest_val)
```

1 PRESENTATION DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION


13 RANDOM FOREST

14 SVM

```
## Area under the curve: 0.7873
```

```
cat("\n")
```

```
plot(roc_curve_random_forest, main = "Courbe ROC", col = "red", lwd = 2)
```



On a un auc de 0.8143, ce qui implique que si on prend au hasard un patient décédé et un patient survivant, le modèle a environ 81 % de chances d'attribuer un score de risque plus élevé au patient décédé.

14 SVM

- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
library(e1071)
```

```
## Warning: le package 'e1071' a été compilé avec la version R 4.5.1
```

```
##
## Attachement du package : 'e1071'
```

```
## L'objet suivant est masqué depuis 'package:flexclust':
##
##      bclust
```

```
calibration_result <- tune.svm(DEATH_EVENT~.,data=HeartFailure_Train,gamma=seq(0.001,1,by=0.01))
calibration_result
```

```
##
## Parameter tuning of 'svm':
##
## - sampling method: 10-fold cross validation
##
## - best parameters:
##   gamma
##   0.041
##
## - best performance: 0.1368646
```

```
svm_result<- svm(as.factor(DEATH_EVENT)~.,data=HeartFailure_Train,gamma=calibration_result$best.p
               arameters)
svm_result
```

1 PRESENTATON DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
##
## Call:
## svm(formula = as.factor(DEATH_EVENT) ~ ., data = HeartFailure_Train,
##      gamma = calibration_result$best.parameters)
##
##
## Parameters:
##   SVM-Type:  C-classification
##   SVM-Kernel: radial
##      cost:  1
##
## Number of Support Vectors:  116
```

14.1 Evaluation : SVM

```
# Prédiction
pred.svm <- predict(svm_result,HeartFailure_Test)
pred.svm
```

```
##  2   3   8  12  15  18  19  28  31  37  38  44  45  47  49  56  62  65  66  68
##  1   1   0   1   1   1   1   1   1   1   1   0   0   1   1   1   0   0   1   1
## 71  80  82  92  95  96  97  99 100 103 114 117 119 120 123 124 129 132 133 138
##   0   0   0   0   0   0   1   1   0   1   0   0   0   1   0   0   0   1   0   1
## 146 148 150 156 162 167 169 171 176 177 183 184 186 187 188 189 194 196 198 202
##   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
## 203 207 208 212 214 219 222 226 230 231 238 242 243 245 247 248 251 259 261 264
##   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0   0
## 266 267 269 274 277 278 280 282 294 299
##   0   0   0   0   0   0   0   0   0   0
## Levels: 0 1
```

```
#mean(svm_result$DEA!=pred.svm)# Taux d'erreur de 0.2108434
```

1 PRESENTATION DE LA
BASE DE DONNEES

2 OBJECTIF

3 ORGANISATION DU
REPERTOIRE DE TRAVAIL

4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN

5 CHARGEMENT DE LA
BASE DE DONNES

6 ANALYSE DESCRIPTIVE

7 PREPARATION DE LA
BASE DE DONNEES :

8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE

9 METHODE DE KMEANS

10 METHODE KNN

11 ANALYSE
DISCRIMINANTE LINEAIRE

12 ARBRE DE DECISION

13 RANDOM FOREST

14 SVM

```
# Matrice de confusion : CART algorithm
confusion_matrix_svm <- confusionMatrix(table(pred.svm, HeartFailure_Test_labels))
print(confusion_matrix_svm)
```

```
## Confusion Matrix and Statistics
##
##      HeartFailure_Test_labels
## pred.svm  0  1
##      0 55 14
##      1  6 15
##
##              Accuracy : 0.7778
##              95% CI : (0.6779, 0.8587)
##      No Information Rate : 0.6778
##      P-Value [Acc > NIR] : 0.02489
##
##              Kappa : 0.4516
##
##  Mcnemar's Test P-Value : 0.11752
##
##              Sensitivity : 0.9016
##              Specificity : 0.5172
##              Pos Pred Value : 0.7971
##              Neg Pred Value : 0.7143
##              Prevalence : 0.6778
##              Detection Rate : 0.6111
##      Detection Prevalence : 0.7667
##              Balanced Accuracy : 0.7094
##
##              'Positive' Class : 0
##
```

```
# Accuracy
accuracy_svm <- confusion_matrix_cart$overall["Accuracy"]
cat("Accuracy SVM is :", accuracy_svm)
```


- 1 PRESENTATION DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
## Accuracy SVM is : 0.7888889
```

Notre modèle arrive à classer 54 individus comme survivants et qui ont bien survécu. Cependant, il déclare 14 survivants qui en réalité sont décédés.

Pour les non survivants, notre modèle catégorise 7 non survivants qui en réalité ont survécu et il arrive à classer 15 non survivants qui sont bien décédés.

En général, notre modèle arrive à être précis à 78,89%

14.2 Courbe de roc

```
roc_curve_svm <- roc(as.numeric(pred.svm), HeartFailure_Test_labels)
```

```
## Setting levels: control = 1, case = 2
```

```
## Setting direction: controls < cases
```


```
auc_svm_val <- auc(roc_curve_svm)
print(auc_svm_val)
```

```
## Area under the curve: 0.7557
```

```
cat("\n")
```

```
plot(roc_curve_svm, main = "Courbe ROC", col = "red", lwd = 2)
```

- 1 PRESENTATON DE LA
BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU
REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET
CHARGEMENT DES
PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA
BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA
BASE DE DONNEES :
- 8 CLASSIFICATION
ASCENDANTE
HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE
DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

Courbe ROC

On a un auc de 0.738, ce qui implique que si on prend au hasard un patient décédé et un patient survivant, le modèle a environ 74 % de chances d'attribuer un score de risque plus élevé au patient décédé.

15 CONCLUSION

- 1 PRESENTATON DE LA BASE DE DONNEES
- 2 OBJECTIF
- 3 ORGANISATION DU REPERTOIRE DE TRAVAIL
- 4 INSTALLATION ET CHARGEMENT DES PACKAGES AVEC PACMAN
- 5 CHARGEMENT DE LA BASE DE DONNES
- 6 ANALYSE DESCRIPTIVE
- 7 PREPARATION DE LA BASE DE DONNEES :
- 8 CLASSIFICATION ASCENDANTE HIERARCHIQUE
- 9 METHODE DE KMEANS
- 10 METHODE KNN
- 11 ANALYSE DISCRIMINANTE LINEAIRE
- 12 ARBRE DE DECISION
- 13 RANDOM FOREST
- 14 SVM

```
list_scoring_model <- c("cah", "kmean", "knn", "lda", "cart", "random forest", "svm")
list_scoring_accuracy <- c(accuracy_cah, accuracy_kMeans, accuracy_knn, accuracy_lda, accuracy_cart, accuracy_random_forest, accuracy_svm)
```

```
table_scoring <- data.frame("modèle" = list_scoring_model, "accuracy" = list_scoring_accuracy)
table_scoring
```

##	modèle	accuracy
## 1	cah	0.4497608
## 2	kmean	0.3888889
## 3	knn	0.5555556
## 4	lda	0.7666667
## 5	cart	0.7888889
## 6	random forest	0.8612440
## 7	svm	0.7888889

On peut conclure que le modèle de Random Forest est le modèle de scoring le plus performant pour prédire la probabilité de décéder de suite d'une insuffisance cardiaque au regard de l'accuracy : 0.861244. Par ailleurs, ce dernier a été utilisé pour identifier les variables qui influencent le plus ce phénomène. Il résulte de cette analyse que le temps après l'insuffisance cardiaque (exprimée en nombre de jour), le taux de créatinine, la fraction d'éjection et l'âge sont les facteurs les plus déterminants.